

# **CREDIT SCORE PREDICTION WITH LINEAR REGRESSION**

- Exploratory Analysis and Graphics
- Treatment of missing data
- Treatment of outliers
- OneHotEncoding
- Attribute Engineering
- Data processing
- Data normalization
- Creation, testing and validation of a machine learning model

### In [1]:

```
# Python Version
from platform import python_version
print('Versão da Linguagem Python Usada Neste Jupyter Notebook:', python_version())
```

Versão da Linguagem Python Usada Neste Jupyter Notebook: 3.9.7

# In [2]:

```
import sys
print(sys.executable)
print(sys.version)
print(sys.version_info)
```

```
C:\Users\User\anaconda3\python.exe
3.9.7 (default, Sep 16 2021, 16:59:28) [MSC v.1916 64 bit (AMD64)]
sys.version_info(major=3, minor=9, micro=7, releaselevel='final', serial=0)
```

```
In [3]:
```

```
# The first step is to import the packages we're going to use.
# Note: Python packages are "group of resources" available in the tool.
# Pandas: It has numerous functions and commands to import files, analyze and manage data etc.
import pandas as pd
# Matplotlib: It has a series of functions and commands for displaying graphs
import matplotlib.pyplot as plt
# Seaborn: It has a series of functions and commands for displaying graphs (More robust visualizations than Matplotlib)
import seaborn as sns
# Numpy: It has a series of functions and commands to work with numbers in general (formatting, calculations, etc.)
import numpy as np
# Time: It has a number of time functions
import time as time
# Warnings: It has details about the warnings and alerts that appear, but we can also use it so that alerts for
# future updates and old methods are not displayed
import warnings
warnings.filterwarnings("ignore")
from sklearn.model_selection import train_test_split # Used to separate training and test data
from sklearn.preprocessing import StandardScaler # Used to normalize the data
from sklearn.preprocessing import MinMaxScaler # Used to normalize the data
from sklearn.preprocessing import LabelEncoder # Used to do OneHotEncoding
from sklearn.linear_model import LinearRegression # Linear Regression Algorithm
from sklearn.metrics import r2_score # Used to measure the accuracy of the predictive model
# Command to display all columns on the file
pd.set_option('display.max_columns', None)
pd.set_option('display.max_rows', None)
In [4]:
# Versions of packages used in this jupyter notebook
%reload_ext watermark
%watermark -a "Score Credit" --iversions
Author: Score Credit
          : 1.22.3
numpy
matplotlib: 3.4.3
        : 1.4.2
pandas
```

```
seaborn
         : 0.11.2
         : 3.9.7 (default, Sep 16 2021, 16:59:28) [MSC v.1916 64 bit (AMD64)]
SVS
```

#### In [5]:

```
# the scikit-learn version
import sklearn
print('The scikit-learn version is {}.'.format(sklearn.__version__))
```

The scikit-learn version is 0.24.2.

# Importação dos dados, Analise Exploratória e Tratamento de Dados

```
In [6]:
```

```
# Command used to load the file and store it as a Pandas DataFrame
# A Pandas DataFrame is like an Excel spreadsheet, where we can manage lines and columns.
# If the excel file is not in the same directory as the script, the path must be specified.
df_dados = pd.read_excel("dados_credito2.xlsx")
```

#### In [7]:

```
# Command used to check the number of lines and columns in the file
# Columns are also called variables.
df_dados.shape
```

# Out[7]:

(10476, 17)

# In [8]:

# Command used to check the initial lines of the DataFrame df\_dados.head()

#### Out[8]:

	CODIGO_CLIENTE	UF	IDADE	ESCOLARIDADE	ESTADO_CIVIL	QT_FILHOS	CASA_PROPRIA	QT_IMOVEIS	VL_IMOVEIS	OUTRA_RENDA
0	1	SP	19	Superior Cursando	Solteiro	0	Não	0	0	Não
1	2	MG	23	Superior Completo	Solteiro	1	Não	0	0	Não
2	3	sc	25	Segundo Grau Completo	Casado	0	Sim	1	220000	Não
3	4	PR	27	Superior Cursando	Casado	1	Sim	0	0	Não
4	5	RJ	28	Superior Completo	Divorciado	2	Não	1	370000	Não
4										<b>+</b>

# In [9]:

# Command used to check the final lines of the DataFrame df\_dados.tail()

#### Out[9]:

	CODIGO_CLIENTE	UF	IDADE	ESCOLARIDADE	ESTADO_CIVIL	QT_FILHOS	CASA_PROPRIA	QT_IMOVEIS	VL_IMOVEIS	OUTRA_RE
10471	10472	PR	51	Superior Completo	Solteiro	1	Não	0	0	
10472	10473	SP	48	Segundo Grau Completo	Casado	0	Sim	1	220000	
10473	10474	RJ	51	Superior Cursando	Casado	1	Sim	0	0	
10474	10475	RJ	48	Superior Completo	Divorciado	2	Não	1	370000	
10475	10476	PR	51	Segundo Grau Completo	Divorciado	0	Não	0	0	

# In [10]:

#Command used to check information about the data (Variable types, Variables, Number of records, etc.) # The variable CODIGO\_CLIENTE can be excluded # The variables UF, ESCOLARIDADE, CASA\_PROPRIA, OUTRA\_RENDA, TRABALHANDO\_ATUALMENTE and ESTADO\_CIVIL --> OneHotEncoding # The variable ULTIMO\_SALARIO is as a STRING and needs to be NUMERIC df\_dados.info()

<class 'pandas.core.frame.DataFrame'> RangeIndex: 10476 entries, 0 to 10475 RangeIndex: 104/0 encises, 5 = 1.

Data columns (total 17 columns):

Non-Null Count Dtype

memory usage: 1.4+ MB

	#	Column	Non-Null Count	Dtype			
	0	CODIGO_CLIENTE	10476 non-null	int64			
	1	UF	10476 non-null	object			
	2	IDADE	10476 non-null	int64			
	3	ESCOLARIDADE	10476 non-null	object			
	4	ESTADO_CIVIL	10476 non-null	object			
	5	QT_FILHOS	10476 non-null	int64			
	6	CASA_PROPRIA	10476 non-null	object			
	7	QT_IMOVEIS	10476 non-null	int64			
	8	VL_IMOVEIS	10476 non-null	int64			
	9	OUTRA_RENDA	10476 non-null	object			
	10	OUTRA_RENDA_VALOR	10476 non-null	int64			
	11	TEMPO_ULTIMO_EMPREGO_MESES	10476 non-null	int64			
	12	TRABALHANDO_ATUALMENTE	10476 non-null	object			
	13	ULTIMO_SALARIO	10474 non-null	object			
	14	QT_CARROS	10476 non-null	int64			
	15	VALOR_TABELA_CARROS	10476 non-null	int64			
	16	SCORE	10476 non-null	float64			
<pre>dtypes: float64(1), int64(9), object(7)</pre>							

```
In [11]:
# Let's delete the CODIGO_CLIENTE variable
df_dados.drop('CODIGO_CLIENTE', axis=1, inplace=True)
In [12]:
# Command used to evaluate if any variable has null value or called values missing or NAN (Not Available)
# The variable ULTIMO_SALARIO has NULL("SEM DADOS") values and we will need to manage it
df_dados.groupby(['ULTIMO_SALARIO']).size()
Out[12]:
ULTIMO_SALARIO
              846
1800
2200
              792
3100
              792
3900
              792
4500
              468
4800
              792
5300
              522
6100
              522
6800
              611
9000
              522
9800
              468
11500
              790
13000
              522
15000
              522
              522
17500
18300
              522
22000
              468
SEM DADOS
dtype: int64
In [13]:
# Here we could solve it in two ways.
# The first way would be to delete the entire record, but we would be losing data.
#df_dados.drop(df_dados.loc[df_dados['VALOR']=='SEM VALOR'].index, inplace=True)
# The second way would be to check the mean or median value of this model and substitute the word NO VALUE for an average value df_dados.loc[df_dados['ULTIMO_SALARIO'] == 'SEM DADOS']
Out[13]:
       UF IDADE ESCOLARIDADE ESTADO_CIVIL QT_FILHOS CASA_PROPRIA QT_IMOVEIS VL_IMOVEIS OUTRA_RENDA OUTRA_RENDA
                         Superior
 10459 RJ
              45
                                       Solteiro
                                                                    Sim
                                                                                         185000
                                                                                                          Sim
                        Cursando
4
In [14]:
# Now we replace the word NO VALUE with a NULL value
df_dados.replace('SEM DADOS',np.nan, inplace = True)
In [15]:
```

# Then convert the field to a float

df\_dados['ULTIMO\_SALARIO'] = df\_dados['ULTIMO\_SALARIO'].astype(np.float64)

```
In [16]:
```

```
# Command used to evaluate if any variable has null value or called values missing or NAN (Not Available)
# The variable ULTIMO_SALARIO has NULL values and we will need to treat them
df_dados.isnull().sum()
Out[16]:
UF
                              0
IDADE
                              0
ESCOLARIDADE
                              0
ESTADO CIVIL
                              0
OT FILHOS
                              a
CASA_PROPRIA
                              0
QT_IMOVEIS
VL_IMOVEIS
                              0
OUTRA_RENDA
                              0
OUTRA_RENDA_VALOR
                              0
TEMPO_ULTIMO_EMPREGO_MESES
                              0
TRABALHANDO_ATUALMENTE
                              0
ULTIMO_SALARIO
                              3
QT_CARROS
                              0
VALOR_TABELA_CARROS
                              0
SCORE
                              0
dtype: int64
In [17]:
# Here we update the value according to the median of that model
df_dados['ULTIMO_SALARIO'] = df_dados['ULTIMO_SALARIO'].fillna((df_dados['ULTIMO_SALARIO'].median()))
In [18]:
# Let's confirm that there are no null values left
df_dados.isnull().sum()
Out[18]:
UF
                              0
IDADE
                              0
ESCOLARIDADE
                              0
ESTADO_CIVIL
                              0
QT FILHOS
                              0
CASA_PROPRIA
                              0
QT_IMOVEIS
                              0
VL_IMOVEIS
OUTRA RENDA
                              0
OUTRA RENDA VALOR
                              a
TEMPO_ULTIMO_EMPREGO_MESES
                              0
TRABALHANDO_ATUALMENTE
                              0
ULTIMO_SALARIO
                              0
QT_CARROS
                              a
VALOR_TABELA_CARROS
                              0
SCORE
dtype: int64
In [19]:
# Let's evaluate the types of the variables again
df_dados.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 10476 entries, 0 to 10475
Data columns (total 16 columns):
 #
     Column
                                 Non-Null Count Dtype
     UF
                                 10476 non-null
 0
                                                 object
     IDADE
 1
                                 10476 non-null
                                                  int64
 2
     ESCOLARIDADE
                                 10476 non-null
                                                  object
 3
     ESTADO_CIVIL
                                 10476 non-null
                                                 object
 4
     OT FILHOS
                                 10476 non-null
                                                  int64
 5
     CASA PROPRIA
                                 10476 non-null
                                                  object
 6
     QT_IMOVEIS
                                 10476 non-null
 7
     VL IMOVEIS
                                 10476 non-null
                                                  int64
 8
     OUTRA_RENDA
                                 10476 non-null
                                                  object
 9
     OUTRA_RENDA_VALOR
                                  10476 non-null
                                                  int64
 10
     TEMPO_ULTIMO_EMPREGO_MESES
                                 10476 non-null
     TRABALHANDO ATUALMENTE
                                  10476 non-null
 11
                                                  obiect
    ULTIMO SALARIO
                                 10476 non-null
 12
                                                  float64
 13
     QT_CARROS
                                  10476 non-null
                                                  int64
 14
    VALOR_TABELA_CARROS
                                  10476 non-null
15 SCORE
                                  10476 non-null float64
dtypes: float64(2), int64(8), object(6)
memory usage: 1.3+ MB
```

```
In [20]:
```

```
# Let's evaluate some basic statistical measures df_dados.describe()
```

#### Out[20]:

	IDADE	QT_FILHOS	QT_IMOVEIS	VL_IMOVEIS	OUTRA_RENDA_VALOR	TEMPO_ULTIMO_EMPREGO_MESES	ULTIMO_SALAF
count	10476.000000	10476.000000	10476.000000	10476.000000	10476.000000	10476.000000	10476.0000
mean	41.054124	1.122566	0.847079	238453.608247	641.237113	43.070447	8286.5311
std	13.878162	1.113537	0.957374	265843.934416	1295.978195	40.851521	5826.5897
min	19.000000	0.000000	0.000000	0.000000	0.000000	8.000000	1800.0000
25%	28.000000	0.000000	0.000000	0.000000	0.000000	14.000000	3900.0000
50%	42.000000	1.000000	1.000000	185000.000000	0.000000	22.000000	6100.0000
75%	53.000000	2.000000	1.000000	370000.000000	0.000000	75.000000	11500.0000
max	65.000000	42.000000	3.000000	900000.000000	4000.000000	150.000000	22000.0000
4							

### In [21]:

```
# Now we will evaluate the outliers of the columns that are numeric
# OUTLIERS are outliers that are far above or far below the other values

# Let's load in a list the variables that are of type INT64 AND FLOAT64
variaveis_numericas = []
for i in df_dados.columns[0:16].tolist():
    if df_dados.dtypes[i] == 'int64' or df_dados.dtypes[i] == 'float64':
        print(i, ':' , df_dados.dtypes[i])
        variaveis_numericas.append(i)
```

IDADE : int64
QT\_FILHOS : int64
QT\_IMOVEIS : int64
VL\_IMOVEIS : int64
OUTRA\_RENDA\_VALOR : int64
TEMPO\_ULTIMO\_EMPREGO\_MESES : int64
ULTIMO\_SALARIO : float64
QT\_CARROS : int64
VALOR\_TABELA\_CARROS : int64
SCORE : float64

# In [22]:

# Let's look at the list of variables and evaluate whether these variables have outliers through a boxplot variaveis\_numericas

### Out[22]:

```
['IDADE',
  'QT_FILHOS',
  'QT_IMOVEIS',
  'VL_IMOVEIS',
  'OUTRA_RENDA_VALOR',
  'TEMPO_ULTIMO_EMPREGO_MESES',
  'ULTIMO_SALARIO',
  'QT_CARROS',
  'VALOR_TABELA_CARROS',
  'SCORE']
```


```
# With this command we will display all graphs of all columns at once to facilitate our analysis.
# Here we define the screen size for displaying the graphs
plt.rcParams["figure.figsize"] = [15.00, 12.00]
plt.rcParams["figure.autolayout"] = True

# Here we define in how many rows and columns we want to display the graphs
f, axes = plt.subplots(2, 5) #2 linhas e 5 colunas

linha = 0
coluna = 0

for i in variaveis_numericas:
    sns.boxplot(data = df_dados, y=i, ax=axes[linha][coluna])
    coluna += 1
    if coluna == 5:
        linha += 1
        coluna = 0

plt.show()
```



### In [24]:

```
# Now we know that we have possible OUTLIERS in the variables QT_FILHOS, QT_IMOVEIS, VALOR_TABELA_CARROS and OUTRA_RENDA_VALOR # Let's look at what these outliers are to evaluate how we will treat them.
```

# Let's list the number of children greater than 4
# Since we only have 2 records that are really outliers, we will exclude them
df\_dados.loc[df\_dados['QT\_FILHOS'] > 4]

### Out[24]:

4

	UF	IDADE	ESCOLARIDADE	ESTADO_CIVIL	QT_FILHOS	CASA_PROPRIA	QT_IMOVEIS	VL_IMOVEIS	OUTRA_RENDA	OUTRA_REND
27	SP	48	Superior Completo	Divorciado	38	Sim	2	600000	Não	
10455	SP	45	Segundo Grau Completo	Casado	42	Sim	1	220000	Não	

```
In [25]:
# In this example we will delete the entire record.
df_dados.drop(df_dados.loc[df_dados['QT_FILHOS'] > 4].index, inplace=True)
In [26]:
# Let's evaluate the other variables with possible outliers
In [27]:
# We don't need to change anything
df_dados.groupby(['OUTRA_RENDA_VALOR']).size()
Out[27]:
OUTRA_RENDA_VALOR
        8350
2400
         468
3000
         612
3200
         522
4000
         522
dtype: int64
In [28]:
# We don't need to change anything
df_dados.groupby(['VALOR_TABELA_CARROS']).size()
Out[28]:
VALOR_TABELA_CARROS
          3762
28000
           468
30000
           791
35000
           792
40000
           792
48000
           522
50000
          1314
70000
           521
80000
           522
150000
           468
180000
           522
dtype: int64
In [29]:
# We don't need to change anything
df_dados.groupby(['QT_IMOVEIS']).size()
Out[29]:
QT_IMOVEIS
0
     4680
1
     3761
2
      989
3
     1044
dtype: int64
```

```
In [30]:
# Let's generate a histogram graph to evaluate the data distribution
# We can see that in this case the data is well dispersed
# Here we define the screen size for displaying the graphs
plt.rcParams["figure.figsize"] = [15.00, 12.00]
plt.rcParams["figure.autolayout"] = True
# Here we define in how many rows and columns we want to display the graphs
f, axes = plt.subplots(4, 3) #4 lines e 3 columns
linha = 0
coluna = 0
for i in variaveis_numericas:
     sns.histplot(data = df_dados, x=i, ax=axes[linha][coluna])
     coluna += 1
     if coluna == 3:
          linha += 1
          coluna = 0
plt.show()
  1200
                                                   3500
                                                                                                   4000
                                                   3000
   1000
                                                   2500
                                                                                                   3000
   800
Count
                                                2000
                                                                                                Count
   600
                                                                                                  2000
                                                   1500
    400
                                                   1000
    200
                                                     0
                                                                                                              0.5
                                                                                                                      1.5
QT IMOVEIS
                                                        0.0
                                                                                2.0
                                                                                            3.0
                         40
IDADE
                                                                       1.5
QT FILHOS
                                                   8000
                                                                                                   2000
   4000
                                                                                                   1500
   3000
2000
                                                5 4000
                                                                                                S 1000
                                                   2000
                                                                                                   500
   1000
                      400000 6
VL_IMOVEIS
                                                            500 1000 1500 2000 2500 3000 3500 4000
OUTRA_RENDA_VALOR
                                                                                                               40 60 80 100 120
TEMPO_ULTIMO_EMPREGO_MESES
                              600000 800000
                                                   3500
                                                                                                   3500
  1500
                                                   3000
                                                                                                   3000
  1250
                                                   2500
                                                                                                   2500
  1000
                                                ğ 2000
                                                                                                Count
                                                                                                   2000
   750
                                                   1500
                                                                                                   1500
    500
                                                   1000
                                                                                                   1000
    250
                                                   500
                                                                                                   500
                                                     0
        2500 5000 7500 10000 12500 15000 17500 20000 22500
                                                       0.00 0.25 0.50 0.75 1.00 1.25 1.50 1.75 2.00
                                                                                                            25000 50000 75000 100000125000150000175000
                     ULTIMO SALARIO
                                                                       QT_CARROS
                                                                                                                   VALOR TABELA CARROS
```

1.0

0.6

0.4

0.2

0.2

0.6

0.8

1.0

0.6

0.4

0.2

0.2

0.6

0.8

1000

600

400


200

```
# Through the hitmap we can observe the correlation between all variables.
plt.rcParams["figure.figsize"] = (18,8)
ax = sns.heatmap(df_dados.corr(), annot=True)
```




#### In [32]:

```
# Let's look at a scatter plot to evaluate the correlation of some variables
sns.lmplot(x = "VL_IMOVEIS", y = "SCORE", data = df_dados);
```



# In [33]:

# Let's look at a scatter plot to evaluate the correlation of some variables
sns.lmplot(x = "ULTIMO\_SALARIO", y = "SCORE", data = df\_dados);



```
In [34]:
# Let's look at a scatter plot to evaluate the correlation of some variables
sns.lmplot(x = "TEMPO_ULTIMO_EMPREGO_MESES", y = "SCORE", data = df_dados);
   100
    80
    60
    40
    20
                                 100
                                             140
            20
                             80
                 TEMPO_ULTIMO_EMPREGO_MESES
In [35]:
# Let's do an attribute engineering in the AGE field and create a new Age Range field
print('Menor Idade: ', df_dados['IDADE'].min())
print('Maior Idade: ', df_dados['IDADE'].max())
Menor Idade: 19
Maior Idade:
In [36]:
# Attribute Engineering - We will create a new variable
idade_bins = [0, 30, 40, 50, 60]
idade_categoria = ["Até 30", "31 a 40", "41 a 50", "Maior que 50"]
df_dados["FAIXA_ETARIA"] = pd.cut(df_dados["IDADE"], idade_bins, labels=idade_categoria)
df_dados["FAIXA_ETARIA"].value_counts()
Out[36]:
Até 30
                  3552
Maior que 50
                  2448
41 a 50
                  2070
31 a 40
                  1270
Name: FAIXA_ETARIA, dtype: int64
In [37]:
# Let's evaluate the average score by age group
df_dados.groupby(["FAIXA_ETARIA"]).mean()["SCORE"]
Out[37]:
FAIXA_ETARIA
                  44.762950
Até 30
31 a 40
                  48.883202
                  51,440177
41 a 50
Maior que 50
                  56.123775
Name: SCORE, dtype: float64
In [38]:
variaveis_categoricas = []
for i in df_dados.columns[0:48].tolist():
         if df_dados.dtypes[i] == 'object' or df_dados.dtypes[i] == 'category':
    print(i, ':' , df_dados.dtypes[i])
              variaveis_categoricas.append(i)
UF : object
ESCOLARIDADE : object
```

ESTADO\_CIVIL : object CASA\_PROPRIA : object OUTRA\_RENDA : object

TRABALHANDO\_ATUALMENTE : object
FAIXA\_ETARIA : category

```
# With this command we will display all graphs of all columns at once to facilitate our analysis.

# Here we define the screen size for displaying the graphs
plt.rcParams["figure.figsize"] = [15.00, 22.00]
plt.rcParams["figure.autolayout"] = True


# Here we define in how many rows and columns we want to display the graphs
f, axes = plt.subplots(4, 2) #3 linhas e 2 colunas

linha = 0
coluna = 0

for i in variaveis_categoricas:
    sns.countplot(data = df_dados, x=i, ax=axes[linha][coluna])

    coluna += 1
    if coluna == 2:
        linha += 1
        coluna = 0

plt.show()
```



# **Data Pre-Processing**

target = df dados.iloc[:,15:16]

```
In [40]:
# Create the encoder
lb = LabelEncoder()
# Apply the encoder to the variables that are with string
df_dados['FAIXA_ETARIA'] = lb.fit_transform(df_dados['FAIXA_ETARIA'])
df_dados['OUTRA_RENDA'] = lb.fit_transform(df_dados['OUTRA_RENDA']) /
df_dados['TRABALHANDO_ATUALMENTE'] = lb.fit_transform(df_dados['TRABALHANDO_ATUALMENTE'])
df_dados['ESTADO_CIVIL'] = lb.fit_transform(df_dados['ESTADO_CIVIL'])
df_dados['CASA_PROPRIA'] = lb.fit_transform(df_dados['CASA_PROPRIA'])
df_dados['ESCOLARIDADE'] = lb.fit_transform(df_dados['ESCOLARIDADE'])
df_dados['UF'] = lb.fit_transform(df_dados['UF'])
# Remove missing values eventually generated
df_dados.dropna(inplace = True)
In [41]:
df_dados.head(5)
Out[41]:
   UF IDADE ESCOLARIDADE ESTADO_CIVIL QT_FILHOS CASA_PROPRIA QT_IMOVEIS VL_IMOVEIS OUTRA_RENDA OUTRA_RENDA_V/
 0
           19
                           2
                                         2
                                                     0
                                                                    0
                                                                                0
                                                                                            0
                                                                                                           0
    0
           23
                           1
                                         2
                                                                    0
                                                                                0
                                                                                            0
                                                                                                           0
 2
     3
           25
                           0
                                         0
                                                     0
                                                                                1
                                                                                        220000
                                                                                                           0
 3
     1
           27
                           2
                                         0
                                                     1
                                                                                0
                                                                                            0
                                                                                                           0
 4
    2
           28
                           1
                                         1
                                                     2
                                                                    0
                                                                                        370000
                                                                                                           0
In [42]:
# Now we can see that we already have all numerical variables
df_dados.info()
<class 'pandas.core.frame.DataFrame'>
Int64Index: 10474 entries, 0 to 10475
Data columns (total 17 columns):
     Column
                                    Non-Null Count Dtype
 0
     UF
                                    10474 non-null int32
 1
     IDADE
                                    10474 non-null int64
     ESCOLARIDADE
                                    10474 non-null
 3
     ESTADO CIVIL
                                    10474 non-null int32
 4
     QT_FILHOS
                                    10474 non-null int64
 5
     CASA_PROPRIA
                                    10474 non-null
                                                     int32
     QT_IMOVEIS
                                    10474 non-null int64
 6
 7
     VL_IMOVEIS
                                    10474 non-null int64
 8
     OUTRA_RENDA
                                    10474 non-null
                                                     int32
     OUTRA_RENDA_VALOR
                                    10474 non-null int64
     TEMPO ULTIMO EMPREGO MESES 10474 non-null
 10
                                                      int64
     TRABALHANDO ATUALMENTE
                                    10474 non-null int32
 11
 12
    ULTIMO_SALARIO
                                    10474 non-null float64
     QT_CARROS
                                    10474 non-null
                                                      int64
 13
    VALOR_TABELA_CARROS
                                    10474 non-null int64
 14
 15 SCORE
                                    10474 non-null
                                                      float64
 16 FAIXA_ETARIA
                                    10474 non-null
                                                      int32
dtypes: float64(2), int32(7), int64(8)
memory usage: 1.4 MB
In [43]:
# Separating the target variable
```

```
In [44]:
```

```
# Separating the predictor variables
preditoras = df_dados.copy() # Making a copy of the dataframe
del preditoras['SCORE'] # Excluding the target variable, as we already separated it in the previous step
preditoras.head()# Visualizing the predictor variables
```

#### Out[44]:

	UF	IDADE	ESCOLARIDADE	ESTADO_CIVIL	QT_FILHOS	CASA_PROPRIA	QT_IMOVEIS	VL_IMOVEIS	OUTRA_RENDA	OUTRA_RENDA_V/
0	4	19	2	2	0	0	0	0	0	_
1	0	23	1	2	1	0	0	0	0	
2	3	25	0	0	0	1	1	220000	0	
3	1	27	2	0	1	1	0	0	0	
4	2	28	1	1	2	0	1	370000	0	
4										<b>&gt;</b>

#### In [45]:

```
# Divisão em Dados de Treino e Teste.

X_treino, X_teste, y_treino, y_teste = train_test_split(preditoras, target, test_size = 0.3, random_state = 40)
```

# In [46]:

```
# Let's apply the normalization in training and testing
# Standardization
sc = MinMaxScaler()
X_treino_normalizados = sc.fit_transform(X_treino)
X_teste_normalizados = sc.transform(X_teste)
```

# Create, evaluate and test our predictive model

# In [47]:

```
# Train the model
modelo = LinearRegression(normalize = True, fit_intercept = True)
modelo = modelo.fit(X_treino_normalizados, y_treino)
```

#### In [48]:

```
r2_score(y_teste, modelo.fit(X_treino_normalizados, y_treino).predict(X_teste_normalizados))
```

#### Out[48]:

0.7984013631162862

# In [49]:

```
UF = 2
IDADE = 42
ESCOLARIDADE = 1
ESTADO_CIVIL = 2
QT_FILHOS = 1
CASA_PROPRIA = 1
QT_IMOVEIS = 1
VL_IMOVEIS = 300000
OUTRA RENDA = 1
OUTRA_RENDA_VALOR = 2000
TEMPO_ULTIMO_EMPREGO_MESES = 18
TRABALHANDO_ATUALMENTE = 1
ULTIMO_SALARIO = 5400.0
QT_CARROS = 4
VALOR_TABELA_CARROS = 70000
FAIXA_ETARIA = 3
novos_dados = [UF, IDADE, ESCOLARIDADE, ESTADO_CIVIL, QT_FILHOS,CASA_PROPRIA,QT_IMOVEIS,VL_IMOVEIS,OUTRA_RENDA,
               OUTRA_RENDA_VALOR, TEMPO_ULTIMO_EMPREGO_MESES, TRABALHANDO_ATUALMENTE, ULTIMO_SALARIO, QT_CARROS,
               VALOR_TABELA_CARROS, FAIXA_ETARIA]
# Reshape
X = np.array(novos_dados).reshape(1, -1)
X = sc.transform(X)
# Prevision
print("Score de crédito previsto para esse cliente:", modelo.predict(X))
```

Score de crédito previsto para esse cliente: [[43.18575662]]

#### In [50]:

# by:https://www.youtube.com/@nerddosdados